Портфолио: Сергей Крежевских

Сергей Крежевских

Prompt Engineer / AI Engineer

https://t.me/SergeyK_70

rosinka_ekt@mail.ru

+7 912 668 0159

2. Вступление / О себе

Я — Prompt Engineer и AI Engineer с опытом работы на авиапредприятии. Специализируюсь на проектировании, оптимизации и внедрении решений на базе больших языковых моделей (LLM).

Моя ключевая суперсила — понимание структуры и потребностей крупных и средних промышленных предприятий. Это позволяет мне грамотно подходить к интеграции искусственного интеллекта в производственную деятельность и создавать решения, которые действительно решают бизнес-задачи.

Стремлюсь автоматизировать и оптимизировать рутинные процессы с помощью ИИ: разрабатываю промпты, создаю ИИ-ассистентов и мультиагентные системы для повышения эффективности бизнеса.

3. Навыки (Skills)

Hard skills:

- Проектирование и внедрение решений на базе LLM.
- Разработка промптов для различных задач (генерация текста, классификация, анализ данных и т.д.).
- Создание ИИ-ассистентов.
- Построение мультиагентных систем.
- Автоматизация бизнес-процессов с использованием ИИ.
- Работа с API языковых моделей.
- Основы машинного обучения и обработки естественного языка (NLP).

Инструменты и технологии:

- **Модели ИИ и сервисы:** OpenAI (GPT, ChatGPT, DALL·E, Whisper), YandexGPT, Yandex-ART, Claude, Gemini, GigaChat, LLaMA, ElevenLabs.
- **Платформы и фреймворки:** LangChain, Hugging Face, Voiceflow.
- **Инструменты автоматизации:** Zapier, Make, n8n, Cursor, Albato.
- **Облачные платформы:** Google Cloud, Yandex Cloud, Koyeb.
- **Среда разработки и коллаборации:** Google Colab, GitHub, Replit, PyCharm.
- **CRM и коммуникации:** AmoCRM, Wazzap.
- **Конструкторы сайтов:** Playground, Creatium, Tilda.

Языки программирования:

- Python.

Soft skills:

- Аналитическое мышление.
- Решение сложных задач.
- Адаптивность к новым технологиям.
- Внимание к деталям.
- Способность объяснять сложные вещи простым языком.

4. Опыт работы

AI Engineer / Prompt Engineer

Освоение новой профессии и применение знаний в области ИИ для решения практических задач. Акцент на автоматизацию и оптимизацию процессов с использованием LLM.

Ключевые достижения:

- Освоил современные инструменты и платформы для работы с ИИ (LangChain, Hugging Face и др.).
- Научился интегрировать языковые модели в рабочие процессы через API.
- Разработал базовые промпты для автоматизации типовых задач.

- Изучил особенности работы популярных LLM (OpenAI, YandexGPT, Claude и др.) и их применимость в бизнес-среде.

Инженер на авиапредприятии

Работа в подразделениях промышленной организации (ОКБ, Производство, серийное обслуживание), где получил понимание:

- структуры и иерархии промышленных предприятий;
- бизнес-процессов на производстве;
- потребностей отделов (инженерия, логистика, планирование, обслуживание);
- специфики документооборота и отчётности.

Этот опыт позволяет мне эффективно переводить бизнес-требования в технические задачи для ИИ-систем.

5. Проекты / Кейсы

Проект 1: RAG-консультант (Gemini + Chroma)

Цель проекта: создание системы поиска и генерации ответов по неструктури - рованным данным (документам компании) для автоматизации консультаций.

Моя роль: AI Engineer / Prompt Engineer.

Инструменты: Python, LangChain, ChromaDB, SentenceTransformers (E5), Google Gemini API, FastAPI, Uvicorn.

Описание:

1. **Задача.** Автоматизировать процесс поиска информации в корпоративных документах и предоставления точных ответов сотрудникам без необходи мости вручную изучать большие объёмы данных.
2. **Решение.** Реализован RAG-пайплайн (Retrieval-Augmented Generation):
    - документы компании индексируются в векторной базе данных Chroma;
    - по запросу пользователя извлекаются релевантные фрагменты из базы;

- извлечённые фрагменты передаются в модель Gemini для генераци и точного ответа с указанием источников.
- разработан CLI-интерфейс и REST API-сервер (на FastAPI + Uvicorn) для взаимодействия с системой.

3. **Трудности и их преодоление:**
   - оптимизация векторного поиска: подобрана модель SentenceTransformers E5 для качественного эмбеддинга;
   - настройка промптов для Gemini: итеративно доработаны промпты для минимизации галлюцинаций, обеспечения ссылок на источники.
4. **Результат:** создан работающий прототип RAG-системы, способный:
   - обрабатывать запросы на естественном языке;
   - предоставлять точные ответы с указанием источников в документах
   - интегрироваться в существующие бизнес-процессы через API.

Проект 2: AI Cafe Bot

Цель проекта: автоматизация заказов в кафе через Telegram-бота с элементами AI (обработка запросов, рекомендации, навигация по меню).

Моя роль: Prompt Engineer / AI Engineer.

Инструменты: Python, SQLite, telebot (pyTelegramBotAPI), OpenAI API, dotenv.

Описание:

1. **Задача.** Упростить процесс заказа в кафе, снизить нагрузку на персонал и повысить удовлетворённость клиентов за счёт автоматизации и персонализированных рекомендаций.
2. **Решение.** Разработан Telegram-бот с:
   - интерактивным меню и корзиной;
   - возможностью оплаты и отслеживания заказов;
   - AI-ассистентом для обработки естественного языка, рекомендаций блюд и ответов на вопросы.

- модульной архитектурой: разделение на работу с БД (SQLite), бизнес-логику и пользовательский интерфейс.

3. **Трудности и их преодоление:**
    - интеграция OpenAI API с Telegram: обеспечена стабильная работа бота при высокой нагрузке;
    - разработка логики рекомендаций: настроены промпты для персонал изации предложений на основе предпочтений пользователя.
4. **Результат:** прототип бота, который:
    - позволяет клиентам делать заказы через Telegram;
    - даёт персонализированные рекомендации;
    - отвечает на вопросы о меню и заведении;
    - снижает нагрузку на персонал кафе.

Проект 3: Быстрый fine-tuning модели T5-small для суммаризации новостей

Цель проекта: демонстрация эффективного и ресурсоэкономичного подхода к fine-tuning LLM для задачи автоматической суммаризации текста с получением в алидных метрик качества (ROUGE) за минимальное время.

Моя роль: AI Engineer.

Инструменты: Hugging Face Transformers, Hugging Face Datasets, PyTorch, Google Colab, ROUGE, датасет CNN/DailyMail.

Описание:

1. **Задача.** Создать модель для суммаризации новостных статей с минималь ными вычислительными затратами, подходящую для прототипирования и быстрого внедрения.
2. **Решение.** Реализован упрощённый pipeline fine-tuning:
    - использована предобученная модель T5-small;
    - заморожены все параметры модели, кроме выходного слоя (lm_head) для снижения вычислительных затрат;
    - подготовлена компактная выборка из датасета CNN/DailyMail (≈2000 train / 200 validation);

- данные токенизированы и поданы в модель в формате «text-to-text»
- обучение проведено через Trainer API (1 эпоха, небольшой batch size, fp16 при наличии GPU);
- оценка модели выполнена с использованием метрики ROUGE.

3. **Трудности и их преодоление:**
   - балансировка размера выборки и качества модели: оптимизирован размер выборки для сохранения репрезентативности данных;
   - контроль переобучения: применены методы регуляризации и валид ация на отдельном наборе данных.
4. **Результат:**
   - получена модель суммаризации с приемлемыми метриками ROUGE
   - продемонстрирован подход к fine-tuning с минимальными ресурсам и (время обучения сокращено на 60 %
     по сравнению с полным обучением)
   - создан шаблон для быстрого прототипирования LLM-решений.

Проект 4: AI Maintenance Assistant (OEE Shopfloor Mnemo)

Цель проекта: разработка прототипа системы мониторинга оборудования и поддержки принятия решений на производстве: от анализа OEE и телеметрии до автоматического формирования заявок на ТО, интеграции с внешними системами.

Моя роль: AI Engineer / Prompt Engineer.

Инструменты: Python, Streamlit, Pandas, OpenAI API, REST (requests), Google Sheets API (gspread), YAML конфигурация.

Описание:

1. **Задача.** Повысить эффективность обслуживания оборудования на производстве за счёт AI-аналитики и автоматизации рутинных операций.
2. **Решение.** Разработан интерактивный прототип системы:
   - визуализация мнемосхемы цеха;
   - анализ OEE и телеметрии (вибрация, температура, ток);

    - генерация AI-рекомендаций с учётом экономического эффекта;
    - автоматическое создание заявок на ТО;
    - интеграции с Google Sheets (BASIC) и Mock ERP API (STANDARD).
3. **Трудности и их преодоление:**
    - обработка разнородных данных телеметрии: стандартизированы форматы данных для анализа;
    - интерпретация AI-рекомендаций: разработаны промпты, объясняющие логику решений на основе числовых метрик.
4. **Результат:** прототип системы, который:
    - визуализирует состояние оборудования в реальном времени;
    - выдаёт AI-рекомендации по обслуживанию с оценкой экономического эффекта;
    - автоматически формирует заявки на ТО;
    - интегрируется с внешними системами учёта.

Проект 5: HR AI Assistant — автообработка резюме в n8n

Цель проекта: автоматизировать первичную обработку входящих резюме: извлечение данных из писем и PDF, проверку на спам/чёрные списки, оценку соответствия вакансии и автоматическую отправку кандидату следующего шага или вежливого отказа, с логированием результатов.

Моя роль: Prompt Engineer / AI Engineer.

Инструменты: n8n (self-hosted, Docker), PostgreSQL, Gmail API (OAuth2), Google Sheets API, OpenAI (LLM), PDF text extraction, JSON Schema.

Описание:

1. **Задача.** Сократить время HR-специалистов на первичную обработку резюме и исключить человеческий фактор на этапе отбора кандидатов.
2. **Решение.** Собран end-to-end workflow в n8n:
    - триггер Gmail ловит новые заявки;
    - система извлекает текст из PDF-вложения;

- LLM приводит информацию о кандидате к структурированному JSON;
- выполняется анти-спам проверка email по правилам, чёрному списку в Google Sheets;
- LLM рассчитывает score «кандидат ↔ вакансия»;
- при score ≥ 60 отправляется письмо с приглашением, иначе — вежливый отказ;
- итоги логируются в Google Sheets для аналитики.

3. **Трудности и их преодоление:**
   - извлечение данных из PDF: оптимизированы методы парсинга для разных форматов резюме;
   - точность оценки соответствия: настроены промпты LLM для кор - ректного расчёта score.
4. **Результат:** workflow, который:
   - автоматизирует первичную обработку резюме;
   - сокращает время отбора кандидатов на 70 %;
   - обеспечивает прозрачность процесса за счёт логирования;
   - освобождает HR-специалистов для стратегических задач.